数据 入和 出

无 我 写什 的程序,目的都是一 的:以某 方式 数据服 我 的目的。 但是数据不由随机位和字 成。我 建立数据元素之 的 系以便于表示 体,或者 世界中存在的 事物 。如果我 知道一个名字和 子 件地址属于同一个人,那 它 将会更有意 。

尽管在 世界中,不是所有的 型相同的 体看起来都是一 的。 一个人可能有一个家庭 号 ,而 一个人只有一个手机号 ,再一个人可能 者兼有。 一个人可能有三个 子 件地址,而 一个人却一个都没有。一位西班牙人可能有 个姓,而 英 的人可能只有一个姓。

面向 象 程 言如此流行的原因之一是 象 我 表示和 理 世界具有潜在的 的数据 的 体 , 到目前 止, 一切都很完美!

但是当我 需要存 些 体 来了, 上,我 以行和列的形式存 数据到 系型数据 中,相当于使用 子表格。正因 我 使用了 不 活的存 媒介 致所有我 使用 象的 活性都 失了。

但是否我 可以将我 的 象按 象的方式来存 ? 我 就能更加 注于 使用 数据,而不是在 子表格的局限性下 我 的 用建模。我 可以重新利用 象的 活性。

一个 象 是基于特定 言的内存的数据 。 了通 送或者存 它,我 需要将它表示成某 准的格式。 JSON 是一 以人可 的文本表示 象的方法。 它已 成 NoSQL 世界交 数据的事 准。当一个 象被序列化成 JSON,它被称 一个 *JSON* 文 。

Elastcisearch 是分布式的 文 存 。它能存 和 索 的数据 —序列化成 JSON文 —以 的方式。 句 ,一旦一个文 被存 在 Elasticsearch 中,它就是可以被集群中的任意 点 索到。

当然,我不要存数据,我一定需要 它,成批且快速的 它。 尽管存的 NoSQL解决方案允 我以文的形式存 象,但是他 旧需要我思考如何 我的数据,以及定 些字段需要被索引以加快数据 索。

在 Elasticsearch 中, 个字段的所有数据 都是 被索引的 。 即 个字段都有 了快速 索 置的 用倒排索引。而且,不像其他多数的数据 ,它能在 相同的 中 使用所有 些倒排索引,并以 人的速度返回 果。

在本章中,我展示了用来建,索,更新和除文的 API。就目前而言,我不心文中的数据或者 它。 所有我 心的就是在 Elasticsearch 中 安全的存文,以及如何将文再次返回。

什 是文 ?

在大多数 用中,多数 体或 象可以被序列化 包含 的 JSON 象。 一个 可以是一个字段或字段的名称,一个 可以是一个字符串,一个数字,一个布 , 一个 象,一些数 ,或一些其它特殊 型 如表示日期的字符串,或代表一个地理位置的 象:

```
{
    "name":
                    "John Smith",
    "age":
                    42,
    "confirmed":
                    true,
                    "2014-06-01",
    "join_date":
    "home": {
        "lat":
                    51.5,
        "lon":
                    0.1
    },
    "accounts": [
        {
            "type": "facebook",
            "id":
                  "johnsmith"
        },
            "type": "twitter",
            "id": "johnsmith"
       }
   ]
}
```

通常情况下,我 使用的 象 和 文 是可以互相替 的。不 ,有一个区 : 一个 象 是 似于 hash 、 hashmap 、字典或者 数 的 JSON 象, 象中也可以嵌套其他的 象。 象可能包含了 外一些 象。在 Elasticsearch 中, 有着特定的含。它是指最 或者根 象, 文 个根 象被序列化成 JSON 并存 到 Elasticsearch 中,指定了唯一 ID。

WARNING 字段的名字可以是任何合法的字符串,但不可以包含 段。

文 元数据

一个文 不 包含它的数据 , 也包含 元数据 — — 有 文 的信息。 三个必 的元数据元素如下:

index

文 在 存放

type

文 表示的 象

_id

文 唯一

index

是因共同的特性被分 到一起的文 集合。例如, 可能存 所有的 品在索引 products 一个 索引 的交易到索引 sales 中。 然也允 存 不相 的数据到一个索引中,但 中,而存 所有 通常看作是一个反模式的做法。

我 将在 [index-management] 介 如何自行 建和管理索引,但 在我 将 Elasticsearch 我 建索引。 所有需要我 做的就是 一个索引名, 个名字必 小写,不能以下 ,不能包含逗号。我 用 website 作 索引名 例。

_type

数据可能在索引中只是松散的 合在一起,但是通常明 定 一些数据中的子分区是很有用的。 例如,所有的 品都放在一个索引中,但是 有 多不同的 品 ,比如 "electronics" 、 "kitchen" 和 "lawn-care"。

些文 共享一 相同的(或非常相似)的模式:他 有一个 、描述、 品代 和 格。他 只是正好属于" 品"下的一些子 。

Elasticsearch 公 了一个称 *types* (型)的特性,它允 在索引中 数据 行 分区。不同 types 的文 可能有不同的字段,但最好能 非常相似。 我 将在 [mapping] 中更多的 于 types 的一些用和限制。

一个 _type 命名可以是大写或者小写,但是不能以下 或者句号 ,不 包含逗号, 并且 度限制 256个字符. 我 使用 blog 作 型名 例。

id

其他元数据

有一些其他的元数据元素,他在 [mapping] 行了介。通前面已列出的元数据元素,我已能存文到 Elasticsearch 中并通 ID 索它— 句 ,使用 Elasticsearch 作文的存介。

索引文

通 使用 <code>index</code> API ,文 可以被 索引 —— 存 和使文 可被搜索。 但是首先,我 要 定文 的位置。正如我 的,一个文 的 <code>_index</code> 、 <code>_type</code> 和 <code>_id</code> 唯一 一个文 。 我 可以提供自定 的 <code>_id</code> ,或者 <code>index</code> API 自 生成。

使用自定 的 ID

如果 的文 有一个自然的 符 (例如,一个 user_account 字段或其他 文 的), 使用如下方式的 index API 并提供 自己 id:

```
PUT /{index}/{type}/{id}
{
    "field": "value",
    ...
}
```

个例子,如果我 的索引称 website , 型称 blog ,并且 123 作 ID ,那 索引 求 是下面 :

```
PUT /website/blog/123
{
    "title": "My first blog entry",
    "text": "Just trying this out...",
    "date": "2014/01/01"
}
```

Elasticsearch 体如下所示:

```
{
    "_index": "website",
    "_type": "blog",
    "_id": "123",
    "_version": 1,
    "created": true
}
```

表明文 已 成功 建, 索引包括 _index 、 _type 和 _id 元数据, 以及一个新元素: _version。

在 Elasticsearch 中 个文 都有一个版本号。当 次 文 行修改 (包括 除), _version 的 会 。 在 理冲突 中,我 了 使用 _version 号 保 的 用程序中的一部分修改不会覆 一部分所做的修改。

Autogenerating IDs

如果 的数据没有自然的 ID, Elasticsearch 可以 我 自 生成 ID。 求的 整 : 不再使用 PUT ("使用 个 URL 存 个文 "),而是使用 POST ("存 文 在 个 URL 命名空 下")。

在 URL 只需包含 _index 和 _type:

```
POST /website/blog/
{
    "title": "My second blog entry",
    "text": "Still trying this out...",
    "date": "2014/01/01"
}
```

```
{
    "_index": "website",
    "_type": "blog",
    "_id": "AVFgSgVHUP18jI2wRx0w",
    "_version": 1,
    "created": true
}
```

自 生成的 ID 是 URL-safe、 基于 Base64 且 度 20个字符的 GUID 字符串。 些 GUID 字符串由可修改的 FlakeID 模式生成, 模式允 多个 点并行生成唯一 ID , 且互相之 的冲突概率几乎 零。

取回一个文

了从 Elasticsearch 中 索出文 , 我 然使用相同的 _index , _type , 和 _id , 但是 HTTP 更改 GET :

```
GET /website/blog/123?pretty
```

体包括目前已 熟悉了的元数据元素,再加上 _source 字段, 个字段包含我 索引数据 送 Elasticsearch 的原始 JSON 文 :

```
{
   "_index" : "website",
   "_type" : "blog",
   "_id" : "123",
   "_version" : 1,
   "found" : true,
   "_source" : {
       "title": "My first blog entry",
       "text": "Just trying this out...",
       "date": "2014/01/01"
   }
}
```

NOTE

在 求的 串参数中加上 pretty 参数,正如前面的例子中看到的, 将会 用 Elasticsearch 的 pretty-print 功能, 功能 使得 JSON 体更加可 。但是, _source 字段不能被格式化打印出来。相反,我 得到的 _source 字段中的 JSON 串,好是和我 它的一 。

GET 求的 体包括 {"found": true} , 了文 已 被 到。 如果我 求一个不存在的文 , 我 旧会得到一个 JSON 体,但是 found 将会是 false 。 此外, HTTP 将会是 404 Not Found ,而不是 200 OK 。

```
curl -i -XGET http://localhost:9200/website/blog/124?pretty
```

示 部的 体在似:

```
HTTP/1.1 404 Not Found
Content-Type: application/json; charset=UTF-8
Content-Length: 83

{
    "_index" : "website",
    "_type" : "blog",
    "_id" : "124",
    "found" : false
}
```

返回文 的一部分

情况下, GET 求会返回整个文 , 个文 正如存 在 _source 字段中的一 。但是也 只其中的 title 字段感 趣。 个字段能用 _source 参数 求得到,多个字段也能使用逗号分隔的列表来指定。

```
GET /website/blog/123?_source=title,text
```

_source 字段 在包含的只是我 求的那些字段,并且已 将 date 字段 掉了。

```
{
    "_index" : "website",
    "_type" : "blog",
    "_id" : "123",
    "_version" : 1,
    "found" : true,
    "_source" : {
        "title": "My first blog entry" ,
        "text": "Just trying this out..."
    }
}
```

或者,如果 只想得到 _source 字段,不需要任何元数据, 能使用 _source 端点:

```
GET /website/blog/123/_source
```

那 返回的的内容如下所示:

```
{
  "title": "My first blog entry",
  "text": "Just trying this out...",
  "date": "2014/01/01"
}
```

文 是否存在

如果只想 一个文 是否存在--根本不想 心内容—那 用 HEAD 方法来代替 GET 方法。 HEAD 求没有返回体,只返回一个 HTTP 求 :

```
curl -i -XHEAD http://localhost:9200/website/blog/123
```

如果文 存在,Elasticsearch 将返回一个 200 ok 的状

```
HTTP/1.1 200 OK
Content-Type: text/plain; charset=UTF-8
Content-Length: 0
```

若文 不存在, Elasticsearch 将返回一个 404 Not Found 的状 :

```
curl -i -XHEAD http://localhost:9200/website/blog/124
```

```
HTTP/1.1 404 Not Found
Content-Type: text/plain; charset=UTF-8
Content-Length: 0
```

当然,一个文 是在 的 候不存在,并不意味着一 秒之后它也不存在:也 同 正好 一个 程 就 建了 文 。

更新整个文

在 Elasticsearch 中文 是不可改 的,不能修改它 。相反,如果想要更新 有的文 ,需要 重建索引或者 行替 ,我 可以使用相同的 index API 行 ,在索引文 中已 行了 。

```
PUT /website/blog/123
{
    "title": "My first blog entry",
    "text": "I am starting to get the hang of this...",
    "date": "2014/01/02"
}
```

```
{
   "_index" : "website",
   "_type" : "blog",
   "_id" : "123",
   "_version" : 2,
   "created": false ①
}
```

① created 志 置成 false , 是因 相同的索引、 型和 ID 的文 已 存在。

在内部,Elasticsearch 已将旧文 已 除,并 加一个全新的文 。 尽管 不能再 旧版本的文 行 ,但它并不会立即消失。当 索引更多的数据,Elasticsearch 会在后台清理 些已 除文 。

在本章的后面部分,我 会介 update API, 个 API 可以用于 partial updates to a document 。 然它似乎 文 直接 行了修改,但 上 Elasticsearch 按前述完全相同方式 行以下 程:

- 1. 从旧文 建 JSON
- 2. 更改 JSON
- 3. 除旧文
- 4. 索引一个新文

唯一的区 在于,update API 通 一个客 端 求来 些 ,而不需要 独的 get 和 index 求。

建新文

当我 索引一个文 , 我 正在 建一个完全新的文 , 而不是覆 有的 ?

住, _index 、 _type 和 _id 的 合可以唯一 一个文 。所以, 保 建一个新文 的最 法是,使用索引 求的 POST 形式 Elasticsearch 自 生成唯一 _id:

```
POST /website/blog/
{ ... }
```

然而,如果已 有自己的 _id ,那 我 必 告 Elasticsearch ,只有在相同的 _index 、 _type 和 _id 不存在 才接受我 的索引 求。 里有 方式,他 做的 是相同的事情。使用 ,取决于 使用起来更方便。

第一 方法使用 op_type -字符串参数:

```
PUT /website/blog/123?op_type=create
{ ... }
```

```
PUT /website/blog/123/_create { ... }
```

如果 建新文 的 求成功 行,Elasticsearch 会返回元数据和一个 201 Created 的 HTTP 。

一方面,如果具有相同的 _index 、 _type 和 _id 的文 已 存在,Elasticsearch 将会返回 409 Conflict ,以及如下的 信息:

```
{
  "error": {
      "root_cause": [
            "type": "document_already_exists_exception",
            "reason": "[blog][123]: document already exists",
            "shard": "0",
            "index": "website"
         }
      ],
      "type": "document_already_exists_exception",
      "reason": "[blog][123]: document already exists",
      "shard": "0",
      "index": "website"
  },
   "status": 409
}
```

除文

除文 的 法和我 所知道的 相同,只是使用 DELETE 方法:

```
DELETE /website/blog/123
```

如果 到 文 , Elasticsearch 将要返回一个 200 ok 的 HTTP , 和一个 似以下 的 体。注意,字段 _version 已 加:

```
{
   "found" : true,
   "_index" : "website",
   "_type" : "blog",
   "_id" : "123",
   "_version" : 3
}
```

```
{
    "found" : false,
    "_index" : "website",
    "_type" : "blog",
    "_id" : "123",
    "_version" : 4
}
```

即使文 不存在(Found 是 false), _version 然会 加。 是 Elasticsearch 内部本的一部分,用来 保 些改 在跨多 点 以正 的 序 行。

正如已 在更新整个文 中提到的, 除文 不会立即将文 从磁 中 除,只是将文NOTE 已 除状 。随着 不断的索引更多的数据,Elasticsearch 将会在后台清理 已 除的文 。

理冲突

当我 使用 index API 更新文 ,可以一次性 取原始文 ,做我 的修改,然后重新索引 整个文 。 最近的索引 求将 :无 最后 一个文 被索引,都将被唯一存 在 Elasticsearch 中。如果其他人同 更改 个文 ,他 的更改将 失。

很多 候 是没有 的。也 我 的主数据存 是一个 系型数据 ,我 只是将数据 制到 Elasticsearch 中并使其可被搜索。 也 个人同 更改相同的文 的几率很小。或者 于我 的 来 偶 失更改并不是很 重的 。

但有 失了一个 更就是 非常 重的 。 想我 使用 Elasticsearch 存 我 上商城商品 存的数量, 次我 一个商品的 候,我 在 Elasticsearch 中将 存数量 少。

有一天,管理 决定做一次促 。突然地,我 一秒要 好几个商品。 假 有 个 web 程序并行 行, 一个都同 理所有商品的 ,如 Consequence of no concurrency control 所示。



Figure 1. Consequence of no concurrency control

web_1 stock_count 所做的更改已 失,因 web_2 不知道它的 stock_count 的拷 已 期。 果我 会 有超 商品的 数量的 存,因 客的 存商品并不存在,我 将 他 非常失望。

更越 繁, 数据和更新数据的 隙越 , 也就越可能 失 更。

在数据 域中,有 方法通常被用来 保并 更新 更不会 失:

悲 并 控制

方法被 系型数据 广泛使用,它假定有 更冲突可能 生,因此阻塞 源以防止冲突。

一个典型的例子是 取一行数据之前先将其 住, 保只有放置 的 程能 一 行数据 行修改。

并 控制

Elasticsearch 中使用的 方法假定冲突是不可能 生的,并且不会阻塞正在 的操作。 然而,如果源数据在 写当中被修改,更新将会失 。 用程序接下来将决定 如何解决冲突。 例如,可以重 更新、使用新的数据、或者将相 情况 告 用 。

并 控制

Elasticsearch 是分布式的。当文 建、更新或 除 , 新版本的文 必 制到集群中的其他 点。Elasticsearch 也是 和并 的, 意味着 些 制 求被并行 送,并且到 目的地 也 序是乱的 。Elasticsearch 需要一 方法 保文 的旧版本不会覆 新的版本。

当我 之前 index , GET 和 delete 求 , 我 指出 个文 都有一个 _version (版本)号,当文 被修改 版本号 。 Elasticsearch 使用 个 _version 号来 保 更以正 序得到 行。如果旧版本的文 在新版本之后到 ,它可以被 的忽略。

我 可以利用 _version 号来 保 用中相互冲突的 更不会 致数据 失。我 通 指定想要修改文 的 version 号来 到 个目的。如果 版本不是当前版本号,我 的 求将会失 。

我 建一个新的博客文章:

```
PUT /website/blog/1/_create
{
    "title": "My first blog entry",
    "text": "Just trying this out..."
}
```

体告 我 , 个新 建的文 _version 版本号是 1 。 在假 我 想 个文 : 我 加 其数据到 web 表 中, 做一些修改, 然后保存新的版本。

首先我 索文:

GET /website/blog/1

体包含相同的 version 版本号 1:

```
{
  "_index" : "website",
  "_type" : "blog",
  "_id" : "1",
  "_version" : 1,
  "found" : true,
  "_source" : {
      "title": "My first blog entry",
      "text": "Just trying this out..."
  }
}
```

在, 当我 通 重建文 的索引来保存修改, 我 指定 version 我 的修改会被 用的版本:

```
PUT /website/blog/1?version=1 ①
{
    "title": "My first blog entry",
    "text": "Starting to get the hang of this..."
}
```

① 我 想 个在我 索引中的文 只有 在的 _version 1 ,本次更新才能成功。

此 求成功, 并且 体告 我 _version 已 到 2:

```
{
    "_index": "website",
    "_type": "blog",
    "_id": "1",
    "_version": 2
    "created": false
}
```

然而,如果我 重新 行相同的索引 求, 然指定 version=1 , Elasticsearch 返回 409 Conflict HTTP ,和一个如下所示的 体:

```
{
   "error": {
      "root cause": [
         {
            "type": "version_conflict_engine_exception",
            "reason": "[blog][1]: version conflict, current [2], provided [1]",
            "index": "website",
            "shard": "3"
         }
      ],
      "type": "version_conflict_engine_exception",
      "reason": "[blog][1]: version conflict, current [2], provided [1]",
      "index": "website",
      "shard": "3"
  },
   "status": 409
}
```

告 我 在 Elasticsearch 中 个文 的当前 _version 号是 2, 但我 指定的更新版本号 1。

我 在 做取决于我 的 用需求。我 可以告 用 其他人已 修改了文 , 并且在再次保存之前 些修改内容。 或者, 在之前的商品 stock_count 景, 我 可以 取到最新的文 并 重新 用 些修改。

所有文 的更新或 除 API,都可以接受 version 参数, 允 在代 中使用 的并 控制, 是一明智的做法。

通 外部系 使用版本控制

一个常 的 置是使用其它数据 作 主要的数据存 ,使用 Elasticsearch 做数据 索, 意味着主数据 的所有更改 生 都需要被 制到 Elasticsearch ,如果多个 程 一数据同 , 可能遇到 似于之前描述的并 。

如果 的主数据 已 有了版本号 — 或一个能作 版本号的字段 比如 timestamp — 那 就可以在 Elasticsearch 中通 加 version_type=external 到 字符串的方式重用 些相同的版本号,版本号必 是大于零的整数,且小于 9.2E+18 — 一个 Java 中 long 型的正 。

外部版本号的 理方式和我 之前 的内部版本号的 理方式有些不同, Elasticsearch 不是 当前 version 和 求中指定的版本号是否相同, 而是 当前 _version 是否 _小于 指定的版本号。 如果 求成功,外部的版本号作 文 的新 _version 行存 。

外部版本号不 在索引和 除 求是可以指定,而且在 建新文 也可以指定。

例如,要 建一个新的具有外部版本号5的博客文章,我 可以按以下方法 行:

```
PUT /website/blog/2?version=5&version_type=external
{
   "title": "My first external blog entry",
   "text": "Starting to get the hang of this..."
}
```

在 中,我 能看到当前的_version版本号是5:

```
{
    "_index": "website",
    "_type": "blog",
    "_id": "2",
    "_version": 5,
    "created": true
}
```

在我 更新 个文 , 指定一个新的 version 号是 10:

```
PUT /website/blog/2?version=10&version_type=external
{
   "title": "My first external blog entry",
   "text": "This is a piece of cake..."
}
```

求成功并将当前_version 10:

```
{
    "_index": "website",
    "_type": "blog",
    "_id": "2",
    "_version": 10,
    "created": false
}
```

如果 要重新 行此 求 ,它将会失 ,并返回像我 之前看到的同 的冲突 , 因 指定的外部版本号不大于 Elasticsearch 的当前版本号。

文 的部分更新

在 更新整个文 , 我 已 介 更新一个文 的方法是 索并修改它,然后重新索引整个文 , 的 如此。然而,使用 update API 我 可以部分更新文 ,例如在某个 求 数器 行累加。

我 也介 文 是不可 的:他 不能被修改,只能被替 。 update API 必 遵循同 的 。 从外部来看,我 在一个文 的某个位置 行部分更新。然而在内部, update API 必 使用与之前描述相同的 索-修改-重建索引 的 理 程。 区 在于 个 程 生在分片内部,

就避免了多次 求的 。通 少 索和重建索引 之 的 ,我 也 少了其他 程的 更 来冲突的可能性。

update 求最 的一 形式是接收文 的一部分作 doc 的参数, 它只是与 有的文 行合并。 象被合并到一起,覆 有的字段, 加新的字段。 例如,我 加字段 tags 和 views 到我 的博客文章,如下所示:

```
POST /website/blog/1/_update
{
    "doc" : {
      "tags" : [ "testing" ],
      "views": 0
    }
}
```

如果 求成功, 我 看到 似于 index 求的 :

```
{
    "_index" : "website",
    "_id" : "1",
    "_type" : "blog",
    "_version" : 3
}
```

索文 示了更新后的_source 字段:

```
{
  "_index":
               "website",
  "_type":
               "blog",
  "_id":
               "1",
  "_version": 3,
  "found":
             true,
  "_source": {
     "title": "My first blog entry",
     "text": "Starting to get the hang of this...",
     "tags": [ "testing" ], ①
     "views": 0 ①
  }
}
```

① 新的字段已被添加到 _source 中。

使用脚本部分更新文

脚本可以在 update API中用来改 _source 的字段内容, 它在更新脚本中称 ctx._source 。 例如,我可以使用脚本来 加博客文章中 views 的数量:

```
POST /website/blog/1/_update
{
    "script" : "ctx._source.views+=1"
}
```

用 Groovy 脚本 程

于那些 API 不能 足需求的情况,Elasticsearch 允 使用脚本 写自定 的 。 多 API都支持脚本的使用,包括搜索、排序、聚合和文 更新。 脚本可以作 求的一部分被 ,从特殊的 .scripts 索引中 索,或者从磁 加 脚本。

的脚本 言 是 Groovy, 一 快速表 的脚本 言, 在 法上与 JavaScript 似。 它在 Elasticsearch V1.3.0 版本首次引入并 行在 沙 中, 然而 Groovy 脚本引 存在漏洞, 允 攻 者通 建 Groovy 脚本, 在 Elasticsearch Java VM 行 脱 沙 并 行 shell 命令。

因此,在版本 v1.3.8 、 1.4.3 和 V1.5.0 及更高的版本中,它已 被 禁用。 此外, 可以通 置集群中的所有 点的 config/elasticsearch.yml 文件来禁用 Groovy 脚本:

```
script.groovy.sandbox.enabled: false
```

将 Groovy 沙 ,从而防止 Groovy 脚本作 求的一部分被接受, 或者从特殊的 .scripts 索引中被 索。当然, 然可以使用存 在 个 点的 config/scripts/ 目 下的 Groovy 脚本。

如果的架和安全性不需要担心漏洞攻,例如的 Elasticsearch 端 暴露和提供可信的用,当它是的用需要的特性,可以 重新用 脚本。

可以在 {ref}/modules-scripting.html[scripting reference documentation] 取更多于脚本的 料。

我 也可以通 使用脚本 tags 数 添加一个新的 。在 个例子中,我 指定新的 作参数,而不是硬 到脚本内部。 使得 Elasticsearch 可以重用 个脚本,而不是 次我想添加 都要 新脚本重新 :

```
POST /website/blog/1/_update
{
    "script" : "ctx._source.tags+=new_tag",
    "params" : {
        "new_tag" : "search"
    }
}
```

取文 并 示最后 次 求的效果:

```
{
  " index":
               "website",
  "_type":
               "blog",
  "_id":
               "1",
  " version": 5,
  "found":
               true,
  "_source": {
     "title": "My first blog entry",
      "text": "Starting to get the hang of this...",
     "tags": ["testing", "search"], ①
     "views": 1 ②
  }
}
```

- ① search 已追加到 tags 数 中。
- ② views 字段已 。
- 我 甚至可以 通 置 ctx.op delete 来 除基于其内容的文 :

```
POST /website/blog/1/_update
{
    "script" : "ctx.op = ctx._source.views == count ? 'delete' : 'none'",
    "params" : {
        "count": 1
    }
}
```

更新的文 可能尚不存在

- 假 我 需要在 Elasticsearch 中存 一个 面 量 数器。 当有用 , 我 面的 数器 行累加。但是,如果它是一个新 , 我 不能 定 数器已 存在。 如果我 更新一个不存在的文 , 那 更新操作将会失 。
- 在 的情况下, 我 可以使用 upsert 参数, 指定如果文 不存在就 先 建它:

```
POST /website/pageviews/1/_update
{
    "script" : "ctx._source.views+=1",
    "upsert": {
        "views": 1
    }
}
```

我 第一次 行 个 求 , upsert 作 新文 被索引,初始化 views 字段 1 。 在后 的 行中,由于文 已 存在,script 更新操作将替代 upsert 行 用, views 数器 行累加。

更新和冲突

了避免数据 失, update API 在 索 索得到文 当前的 version 号,并 版本号到 _ 重建索引 的 index 求。如果 一个 程修改了 于 索和重新索引 之 的文 ,那 _version 号将不匹配,更新 求将会失 。

于部分更新的很多使用 景,文 已 被改 也没有 系。 例如,如果 个 程都 面 量 数器 行 操作,它 生的先后 序其 不太重要; 如果冲突 生了,我 唯一需要做的就是 再次更新。

可以通 置参数 retry_on_conflict 来自 完成, 个参数 定了失 之前 update 重的次数,它的 0。

```
POST /website/pageviews/1/_update?retry_on_conflict=5 ①
{
    "script" : "ctx._source.views+=1",
    "upsert": {
        "views": 0
    }
}
```

① 失 之前重 更新5次。

在 量操作无 序的 景,例如 数器等 个方法十分有效,但是在其他情况下 更的 序 是 非常重要的。 似 index API , update API 采用 最 写入生效 的方案,但它也接受一个 version 参数来允 使用 optimistic concurrency control 指定想要更新文 的版本。

取回多个文

Elasticsearch 的速度已 很快了,但甚至能更快。 将多个 求合并成一个,避免 独 理 个 求花 的 延和 。如果 需要从 Elasticsearch 索很多文 ,那 使用 multi-get 或者 mget API 来将 些 索 求放在一个 求中,将比逐个文 求更快地 索到全部文 。

mget API 要求有一个 docs 数 作 参数, 个元素包含需要 索文 的元数据, 包括 _index 、 _type 和 _id 。如果 想 索一个或者多个特定的字段, 那 可以通 _source 参数来指定 些字段的名字:

```
GET /_mget
{
  "docs" : [
     {
        "_index" : "website",
        "_type" : "blog",
        "_id" :
                 2
     },
        "_index" : "website",
        "_type": "pageviews",
        "_id": 1,
        "_source": "views"
     }
  ]
}
```

体也包含一个 docs 数 , 于 一个在 求中指定的文 , 个数 中都包含有一个 的 , 且 序与 求中的 序相同。 其中的 一个 都和使用 个 get request 求所得到的体相同:

```
{
  "docs" : [
     {
        "_index" : "website",
        "_id": "2",
        "_type": "blog",
        "found": true,
        "_source" : {
          "text": "This is a piece of cake...",
         "title" : "My first external blog entry"
        "_version" : 10
     },
        "_index" : "website",
        "_id" :
                  "1",
        "_type" : "pageviews",
        "found": true,
        "_version" : 2,
        "_source" : {
          "views" : 2
        }
     }
  ]
}
```

如果想 索的数据都在相同的 _index 中(甚至相同的 _type 中), 可以在 URL 中指定 的 /_index

然可以通 独 求覆 些 :

事 上,如果所有文 的 _index 和 _type 都是相同的, 可以只 一个 ids 数 ,而不是整个 docs 数 :

```
GET /website/blog/_mget
{
    "ids" : [ "2", "1" ]
}
```

注意,我 求的第二个文 是不存在的。我 指定 型 blog ,但是文 ID 1 的 型是 pageviews , 个不存在的情况将在 体中被 告:

```
{
 "docs" : [
     "_index": "website",
     "_type" :
                 "blog",
     " id" :
                 "2",
     "_version" : 10,
     "found": true,
     "_source" : {
      "title":
                "My first external blog entry",
       "text":
                 "This is a piece of cake..."
     }
   },
     "_index" :
                 "website",
     "_type":
                 "blog",
     "_id" :
                 "1",
     "found": false ①
   }
 ]
}
```

① 未 到 文 。

事 上第二个文 未能 到并不妨碍第一个文 被 索到。 个文 都是 独 索和 告的。

NOTE

即使有某个文 没有 到,上述 求的 HTTP 状 然是 200。事 上,即使 求 没有 到任何文 ,它的状 依然是 200 --因 mget 求本身已 成功 行。 了 定某个文 是成功或者失 , 需要 found 。

代 小的批量操作

与 mget 可以使我 一次取回多个文 同 的方式, bulk API 允 在 个 中 行多次 create 、 index 、 update 或 delete 求。如果 需要索引一个数据流比如日志事件,它可以排 和索引数百或数千批次。

bulk 与其他的 求体格式 有不同,如下所示:

```
{ action: { metadata }}\n
{ request body        }\n
{ action: { metadata }}\n
{ request body     }\n
...
```

格式 似一个有效的 行 JSON 文 流,它通 行符(\n) 接到一起。注意 个要点:

- 行一定要以 行符(\n) 尾,包括最后一行。 些 行符被用作一个 ,可以有效分隔行。
- 些行不能包含未 的 行符,因 他 将会 解析造成干 。 意味着 个 JSON 不 能使用 pretty 参数打印。

TIP 在 [bulk-format] 中,我 解 什 bulk API 使用 格式。

action/metadata 行指定 一个文 做 什 操作。

action 必 是以下 之一:

create

如果文 不存在,那 就 建它。 情 建新文 。

index

建一个新文 或者替 一个 有的文 。 情 索引文 和 更新整个文 。

update

部分更新一个文 。 情 文 的部分更新。

delete

除一个文 。 情 除文 。

metadata 指定被索引、 建、更新或者 除的文 的 _index 、 _type 和 _id。

例如,一个 delete 求看起来是 的:

```
{ "delete": { "_index": "website", "_type": "blog", "_id": "123" }}
```

request body 行由文 的 _source 本身 成—文 包含的字段和 。它是 index 和 create

操作所必需的, 是有道理的: 必 提供文 以索引。

它也是 update 操作所必需的,并且 包含 update API 的相同 求体: doc 、 upsert 、 script 等等。 除操作不需要 request body 行。

```
{ "create": { "_index": "website", "_type": "blog", "_id": "123" }}
{ "title": "My first blog post" }
```

如果不指定_id,将会自 生成一个ID:

```
{ "index": { "_index": "website", "_type": "blog" }}
{ "title": "My second blog post" }
```

了把所有的操作。合在一起,一个完整的 bulk 求 有以下形式:

```
POST /_bulk
{ "delete": { "_index": "website", "_type": "blog", "_id": "123" }} ①
{ "create": { "_index": "website", "_type": "blog", "_id": "123" }}
{ "title": "My first blog post" }
{ "index": { "_index": "website", "_type": "blog" }}
{ "title": "My second blog post" }
{ "update": { "_index": "website", "_type": "blog", "_id": "123", "_retry_on_conflict": 3} }
{ "doc": {"title": "My updated blog post"} } ②
```

- ① 注意 delete 作不能有 求体,它后面跟着的是 外一个操作。
- ② 最后一个 行符不要落下。

个 Elasticsearch 包含 items 数 , 个数 的内容是以 求的 序列出来的 个 求的 果。

```
{
   "took": 4,
   "errors": false, ①
   "items": [
      { "delete": {
            " index":
                       "website",
           "_type":
                       "blog",
           __id":
                       "123",
            "_version": 2,
            "status":
                        200,
            "found":
                       true
      }},
      { "create": {
            "_index":
                       "website",
            "_type":
                       "blog",
           "_id":
                        "123",
            " version": 3,
            "status":
                        201
      }},
        "create": {
            "_index":
                       "website",
            _type":
                        "blog",
            "_id":
                        "EiwfApScQiiy7TIKFxRCTw",
            "_version": 1,
            "status":
                       201
      }},
      { "update": {
            "_index":
                       "website",
            "_type":
                        "blog",
            "_id":
                       "123",
            " version": 4,
            "status":
                       200
     }}
  ]
}
```

① 所有的子 求都成功完成。

个子 求都是独立 行,因此某个子 求的失 不会 其他子 求的成功与否造成影 。 如果其中任何子 求失 ,最 的 error 志被 置 true ,并且在相 的 求 告出 明 :

```
POST /_bulk
{ "create": { "_index": "website", "_type": "blog", "_id": "123" }}
{ "title": "Cannot create - it already exists" }
{ "index": { "_index": "website", "_type": "blog", "_id": "123" }}
{ "title": "But we can update it" }
```

在 中,我 看到 create 文 123 失 ,因 它已 存在。但是随后的 index 求,也是 文 123 操作,就成功了:

```
{
   "took": 3,
   "errors": true, ①
   "items": [
      { "create": {
            " index":
                         "website",
            "_type":
                         "blog",
            "_id":
                         "123",
            "status":
                         409, 2
            "error":
                         "DocumentAlreadyExistsException 3
                         [[website][4] [blog][123]:
                         document already exists]"
      }},
         "index": {
            "_index":
                         "website",
            "_type":
                         "blog",
            "_id":
                        "123",
            " version": 5,
            "status":
                        200 (4)
      }}
  ]
}
```

- ① 一个或者多个 求失 。
- ② 个 求的HTTP状 告 409 CONFLICT。
- ③解 什 求失 的 信息。
- ④ 第二个 求成功,返回 HTTP 状 200 OK。

也意味着 bulk 求不是原子的: 不能用它来 事 控制。 个 求是 独 理的,因此一个 求的成功或失 不会影 其他的 求。

不要重 指定Index和Type

也 正在批量索引日志数据到相同的 index 和 type 中。 但 一个文 指定相同的元数据是一 浪 。相反,可以像 mget API 一 ,在 bulk 求的 URL 中接收 的 /_index 或者 /_index/_type :

```
POST /website/_bulk
{ "index": { "_type": "log" }}
{ "event": "User logged in" }
```

然可以覆 元数据行中的 _index 和 _type , 但是它将使用 URL 中的 些元数据 作 :

```
POST /website/log/_bulk
{ "index": {}}
{ "event": "User logged in" }
{ "index": { "_type": "blog" }}
{ "title": "Overriding the default type" }
```

多大是太大了?

幸 的是,很容易 到 个 最佳点 :通 批量索引典型文 ,并不断 加批量大小 行 。 当性能 始下降,那 的批量大小就太大了。一个好的 法是 始 将 1,000 到 5,000 个文 作 一个批次,如果 的文 非常大,那 就 少批量的文 个数。

密切 注 的批量 求的物理大小往往非常有用,一千个 1KB 的文 是完全不同于一千个 1MB 文 所占的物理大小。一个好的批量大小在 始 理后所占用的物理大小 5-15 MB。